

Regresión Lineal para estimar la esperanza de vida al nacer a partir de indicadores socioeconómicos de países

Autor	Jonnathan David Pasos Pazos
Curso	Especialización en analítica y ciencia de datos Machine Learning – Semestre 1
Fecha	17 de septiembre de 2026
Repositorio	https://github.com/sergiojrivers0712-bot/TRABAJO-REGRESION-LOGISTICA/tree/main

Resumen ejecutivo

Este informe documenta el desarrollo completo de un modelo de Regresión Lineal que estima la **esperanza de vida al nacer** de un país (2019) a partir de cinco indicadores socioeconómicos: PIB per cápita, gasto en salud per cápita, población urbana, matrícula bruta en secundaria y proporción de usuarios de internet. Los datos provienen de la API pública del Banco Mundial (World Bank Open Data) y, tras aplicar criterios de calidad y limpieza, el dataset final cubre **131 países**. El modelo, ajustado sobre un 80% de los datos y evaluado sobre el 20% restante (semilla fija = 42), explica aproximadamente el **82% de la varianza** de la esperanza de vida en el conjunto de prueba ($R^2 = 0.82$) con un error promedio (MAE) de **2.3 años**. El predictor más influyente es el porcentaje de usuarios de internet, seguido de la matrícula en secundaria; el PIB per cápita y el gasto en salud, aunque relevantes, están altamente correlacionados entre sí (colinealidad), por lo que su efecto individual debe interpretarse con cautela. Los supuestos de homocedasticidad y ausencia de autocorrelación se sostienen razonablemente, pero los residuos muestran una desviación significativa de la normalidad, una limitación que se discute en la sección de conclusiones. El repositorio con el código Python completo (recolección, EDA, modelado y evaluación) está enlazado al final de este documento.

1. Definición del problema y método de recolección

1.1 Definición del problema

Variable objetivo (continua): esperanza de vida al nacer, en años (indicador *SP.DYN.LE00.IN*).

Predictores (5):

- PIB per cápita (US\$ corrientes) — *NY.GDP.PCAP.CD*
- Gasto en salud per cápita (US\$ corrientes) — *SH.XPD.CHEX.PC.CD*
- Población urbana (% del total) — *SP.URB.TOTL.IN.ZS*
- Matrícula bruta en educación secundaria (%) — *SE.SEC.ENRR*
- Usuarios de internet (% de la población) — *IT.NET.USER.ZS*

Unidad de análisis: país. Año de referencia: 2019 (último año prepandemia con buena cobertura de datos en los cinco indicadores).

1.2 Fuente y pasos de recolección

Los datos se obtuvieron de la **API REST pública del Banco Mundial** (<https://api.worldbank.org/v2/>), que no requiere autenticación. El script *src/collect_data.py* del repositorio ejecuta, en orden: (1) descarga paginada de los metadatos de todos los países/agregados vía el endpoint */country*, usados para distinguir países reales de agregados regionales; (2) para cada uno de los 6 indicadores (objetivo + 5 predictores), una llamada a

/country/al/indicator/<codigo>?date=2019 que trae el valor de todos los países en un solo request. Cada llamada HTTP se registra con marca de tiempo, URL exacta y código de respuesta en *data/raw/collection_log.csv*, y la respuesta JSON cruda se guarda sin modificar en *data/raw/* para permitir auditoría del dato tal como lo entregó la fuente.

1.3 Criterios de calidad aplicados

Criterio	Efecto
Excluir agregados regionales/de ingreso (p. ej. “World”, “OECD miembros”)	-46 filas
Eliminar duplicados exactos por país	0 filas adicionales
Eliminar filas con datos faltantes en objetivo o predictores	-84 filas
Descartar valores no físicos (esperanza de vida fuera de 0-120 años; predictores negativos)	0 filas adicionales

Resultado: de 260 registros del indicador objetivo, el dataset final de modelado queda en **131 países** con datos completos y válidos en las 6 variables (ver *reportes/quality_log.json*).

2. Preparación y análisis exploratorio (EDA)

El diccionario de variables completo está en *data/procesad/diccionario_variables.csv*. La tabla siguiente resume los estadísticos descriptivos de las variables del modelo (n = 131 países):

Variable	Media	Desv. está.	Min	Mediana	Max
Esperanza de vida (años)	75.0	6.5	53.0	75.8	85.3
PIB per cápita (US\$)	20 191	25 245	234	9 395	166 908
Gasto en salud per cápita (US\$)	1 574	2 175	16	639	10 550
Población urbana (%)	64.4	21.7	13.9	67.2	100.0
Matricula secundaria (%)	92.2	24.8	20.2	96.2	156.6
Usuarios de internet (%)	68.6	23.8	6.1	73.7	99.7

La correlación de Pearson de cada predictor con la variable objetivo es: usuarios de internet $r = 0.83$ (la más fuerte), matricula secundaria $r = 0.71$, PIB per cápita $r = 0.66$, gasto en salud $r = 0.64$ y población urbana $r = 0.61$. Se observa además una correlación muy alta entre PIB per cápita y gasto en salud per cápita ($r = 0.91$), lo cual anticipa un problema de multicolinealidad que se confirma más adelante (sección 3.2).




Figura 1. Matriz de correlación de Pearson entre la variable objetivo y los predictores.




Figura 2. Dispersión de cada predictor frente a la esperanza de vida. El PIB y el gasto en salud muestran una relación de tipo logarítmico (rendimientos decrecientes); los demás predictores muestran una relación más lineal.

Lectura breve: los países con mayor acceso a internet, mayor matrícula educativa y mayor ingreso tienden a tener mayor esperanza de vida, consistente con la literatura de desarrollo humano. La relación con el ingreso (PIB, gasto en salud) no es estrictamente lineal — se aplana en niveles altos —, lo cual es una limitación conocida de un modelo puramente lineal (ver sección 5).

3. Modelado

3.1 Configuración

Se dividió el dataset en **80% entrenamiento (104 países)** y **20% prueba (27 países)** usando *train_test_split* de scikit-learn con semilla fija **random_state = 42** (definida centralmente en *src/config.py* para garantizar reproducibilidad). Se ajustó una **Regresión Lineal Múltiple** (*sklearn.linear_model.LinearRegression*) sobre los 5 predictores estandarizados en su escala original (sin transformar).

3.2 Coeficientes estimados

Variable	Coefficiente
Intercepto	59.78
PIB per cápita (US\$)	5.91e-05
Gasto en salud per cápita (US\$)	2.33e-04
Población urbana (%)	0.0203
Matrícula secundaria (%)	0.0238
Usuarios de internet (%)	0.1467

El coeficiente de *usuarios de internet* es el de mayor magnitud estandarizada dado el rango similar de las variables porcentuales: cada punto porcentual adicional de población con acceso a internet se asocia, en promedio y manteniendo lo demás constante, con ~0.15 años más de esperanza de vida.

3.3 Validación de supuestos (sobre el set de entrenamiento)

Supuesto	Prueba	Resultado	Conclusión
Homocedasticidad	Bruch-Pagan	LM = 9.98, p = 0.076	No se rechaza H0: sin evidencia fuerte de heterocedasticidad
Autocorrelación	Durbin-Watson	DW = 2.04	Cercano a 2: sin autocorrelación de primer orden
Normalidad de residuos	Shapiro-Wilk	W = 0.951, p < 0.001	Se rechaza H0: los residuos se desvían de la normalidad
Multicolinealidad	VIF	PIB = 6.26, Salud = 5.29, resto < 4	PIB y gasto en salud requieren atención (colineales entre sí)

(Nota metodológica: dado que *statsmodels* es opcional según los requisitos técnicos del proyecto y

no estuvo disponible en el entorno de ejecución, los tests de Breusch-Pagan, Durbin-Watson y VIF se implementaron de forma manual con *scipy* y *scikit-learn* en *src/model.py*, siguiendo sus definiciones estadísticas estándar.)




Figura 3. Residuos vs. valores ajustados (entrenamiento): la dispersión es razonablemente pareja alrededor de cero, sin un patrón de embudo marcado.




Figura 4. QQ-plot de residuos: las colas se apartan de la recta teórica, reflejando la falta de normalidad detectada por Shapiro-Wilk.

4. Evaluación del modelo

Las métricas se calcularon sobre el conjunto de prueba (27 países, no vistos durante el ajuste) y se comparan con el conjunto de entrenamiento para descartar sobreajuste:

Métrica	Entrenamiento (n=104)	Prueba (n=27)
MAE (años)	2.49	2.31
MSE	11.65	8.64
RMSE (años)	3.41	2.94
R ²	0.715	0.817

El desempeño en prueba es igual o mejor que en entrenamiento, lo que descarta sobreajuste (el modelo no "memorizo" el set de entrenamiento); la diferencia es atribuible al tamaño pequeño del set de prueba (27 países). En promedio, el modelo se equivoca por **~2.3 años** al estimar la esperanza de vida de un país, y explica el **82%** de su variabilidad usando solo 5 indicadores socioeconómicos.




Figura 5. Esperanza de vida real vs. predicha (set de prueba). Los puntos cercanos a la línea $y=x$ indican buenas predicciones.




Figura 6. Residuos vs. predicciones: sin patrón sistemático evidente, aunque con un par de valores atípicos (países con esperanza de vida inusualmente alta o baja para su nivel socioeconómico).

5. Conclusiones, limitaciones y trabajo futuro

5.1 Hallazgos principales

- El acceso a internet, la matrícula educativa y el nivel de ingreso de un país explican en conjunto una parte sustancial ($R^2 = 0.82$) de las diferencias en esperanza de vida al nacer entre países.
- El predictor individualmente más asociado con la esperanza de vida es el porcentaje de usuarios de internet ($r = 0.83$), probablemente como proxy de desarrollo institucional y acceso a información/servicios, más que una relación causal directa.
- PIB per cápita y gasto en salud per cápita aportan información redundante entre sí ($r = 0.91$, $VIF > 5$); un modelo más parsimonioso podría combinarlos o retener solo uno de los dos.

5.2 Sesgos y limitaciones

- **No linealidad no capturada:** la relación entre ingreso/gasto en salud y esperanza de vida se aplanan en niveles altos (rendimientos decrecientes); una Regresión Lineal simple subestima este efecto en los extremos.
- **Residuos no normales** (Shapiro-Wilk, $p < 0.001$): los intervalos de confianza de los coeficientes deben interpretarse con cautela; no invalida las predicciones puntuales, pero sí la inferencia estadística exacta.
- **Multicolinealidad moderada** entre PIB y gasto en salud dificulta aislar el efecto individual de cada uno.
- **Variable de un solo año (2019) y de nivel-país:** el modelo no captura dinámicas temporales ni heterogeneidad dentro de cada país (regiones, grupos socioeconómicos).
- **Variables omitidas:** factores como calidad institucional, desigualdad de ingreso, o acceso efectivo (no solo gasto) a servicios de salud no se incluyeron y podrían confundir las relaciones estimadas.

5.3 Mejoras futuras

- Probar transformaciones no lineales (log del PIB y del gasto en salud) o modelos no lineales (Random Forest, Gradient Boosting) y comparar su desempeño frente a esta línea base.
- Incorporar más años (panel de datos) para modelar tendencias y usar validación cruzada en lugar de un único split train/test.
- Aplicar regularización (Ridge/Lasso) para mitigar la multicolinealidad entre PIB y gasto en salud.
- Incluir variables adicionales de gobernanza, desigualdad (Índice de Gini) y acceso efectivo a servicios de salud.

6. Repositorio GitHub

Enlace del repositorio: <https://github.com/sergiojriviera0712-bot/TRABAJO-REGRESI-N-LOGISTICA/tree/main>

Estructura del proyecto:

```
regresion-lineal-esperanza-vida/
|-- README.md                (instrucciones de instalacion y ejecucion)
|-- requirements.txt          (dependencias con versiones minimas)
|-- Informe_RegresionLineal_PasosPazosJonnathanDavid.pdf      (este informe)
|-- src/
|   |-- config.py             (semilla, rutas relativas, indicadores)
|   |-- collect_data.py       (Paso 1: recoleccion via API Banco Mundial)
|   |-- prepare_and_eda.py    (Paso 2: limpieza, diccionario, EDA)
|   |-- model.py              (Paso 3: split, ajuste, supuestos)
|   |-- evaluate.py           (Paso 4: metricas y graficos de evaluacion)
|-- data/
|   |-- raw/                  (JSON crudos + collection_log.csv)
|   |-- processed/            (dataset.csv, train.csv, test.csv, diccionario)
|-- figures/                  (todas las figuras de este informe, en .png)
-- reports/                   (metricas y estadisticos en .json / .csv)
```

Requisitos técnicos: Python 3.10+; librerías *pandas*, *numpy*, *scikit-learn*, *matplotlib*, *requests*, *scipy* (versión completa en *requirements.txt*), El *README.md* del repositorio detalla los pasos exactos de instalación y ejecución de los 4 scripts, en orden, para reproducir íntegramente este informe a partir de datos crudos.