

Regresion Lineal para estimar la esperanza de vida al nacer a partir de indicadores socioeconomicos de paises

Un flujo completo de ciencia de datos: recoleccion, preparacion, modelado y evaluacion

Autor	Jonnathan David Pasos Pazos
Tipo de proyecto	Proyecto personal de analisis de datos (Regresion Lineal)
Fecha	18 de septiembre de 2026
Repositorio	https://github.com/tu-usuario/regresion-lineal-esperanza-vida

Resumen ejecutivo

Este informe documenta el desarrollo completo de un modelo de Regresion Lineal que estima la **esperanza de vida al nacer** de un pais (2019) a partir de cinco indicadores socioeconomicos: PIB per capita, gasto en salud per capita, poblacion urbana, matricula bruta en secundaria y proporcion de usuarios de internet. Los datos provienen de la API publica del Banco Mundial (World Bank Open Data) y, tras aplicar criterios de calidad y limpieza, el dataset final cubre **131 paises**. El modelo, ajustado sobre un 80% de los datos y evaluado sobre el 20% restante (semilla fija = 42), explica aproximadamente el **82% de la varianza** de la esperanza de vida en el conjunto de prueba ($R^2 = 0.82$) con un error promedio (MAE) de **2.3 años**. El predictor mas influyente es el porcentaje de usuarios de internet, seguido de la matricula en secundaria; el PIB per capita y el gasto en salud, aunque relevantes, estan altamente correlacionados entre si (colinealidad), por lo que su efecto individual debe interpretarse con cautela. Los supuestos de homocedasticidad y ausencia de autocorrelacion se sostienen razonablemente, pero los residuos muestran una desviacion significativa de la normalidad, una limitacion que se discute en la seccion de conclusiones. El repositorio con el codigo Python completo (recoleccion, EDA, modelado y evaluacion) esta enlazado al final de este documento.

1. Definicion del problema y metodo de recoleccion

1.1 Definicion del problema

Variable objetivo (continua): esperanza de vida al nacer, en años (indicador *SP.DYN.LE00.IN*).

Predictores (5):

- PIB per capita (US\$ corrientes) — *NY.GDP.PCAP.CD*
- Gasto en salud per capita (US\$ corrientes) — *SH.XPD.CHEX.PC.CD*
- Poblacion urbana (% del total) — *SP.URB.TOTL.IN.ZS*
- Matricula bruta en educacion secundaria (%) — *SE.SEC.ENRR*
- Usuarios de internet (% de la poblacion) — *IT.NET.USER.ZS*

Unidad de analisis: pais. **Anio de referencia:** 2019 (ultimo anio pre-pandemia con buena cobertura de datos en los cinco indicadores).

1.2 Fuente y pasos de recoleccion

Los datos se obtuvieron de la **API REST publica del Banco Mundial** (<https://api.worldbank.org/v2/>), que no requiere autentificacion. El script *src/collect_data.py* del repositorio ejecuta, en orden: (1) descarga paginada de los metadatos de todos los paises/agregados via el endpoint */country*, usados para distinguir paises reales de agregados regionales; (2) para cada uno de los 6 indicadores (objetivo + 5 predictores), una llamada a */country/all/indicator/<codigo>?date=2019* que trae el valor de todos los paises en un solo request. Cada llamada HTTP se registra con marca de tiempo, URL exacta y codigo de respuesta en *data/raw/collection_log.csv*, y la respuesta JSON cruda se guarda sin modificar en *data/raw/* para permitir auditoria del dato tal como lo entrego la fuente.

1.3 Criterios de calidad aplicados

Criterio	Efecto
Excluir agregados regionales/de ingreso (p. ej. "World", "OECD members")	-46 filas
Eliminar duplicados exactos por pais	0 filas adicionales
Eliminar filas con datos faltantes en objetivo o predictores	-84 filas

Descartar valores no físicos (esperanza de vida fuera de 0-120 años; predictores negativos)	0 filas adicionales
---	---------------------

Resultado: de 260 registros del indicador objetivo, el dataset final de modelado queda en **131 países** con datos completos y validos en las 6 variables (ver *reports/quality_log.json*).

2. Preparacion y analisis exploratorio (EDA)

El diccionario de variables completo esta en *data/processed/diccionario_variables.csv*. La tabla siguiente resume los estadisticos descriptivos de las variables del modelo (n = 131 paises):

Variable	Media	Desv. est.	Min	Mediana	Max
Esperanza de vida (anios)	75.0	6.5	53.0	75.8	85.3
PIB per capita (US\$)	20 191	25 245	234	9 395	166 908
Gasto en salud per capita (US\$)	1 574	2 175	16	639	10 550
Poblacion urbana (%)	64.4	21.7	13.9	67.2	100.0
Matricula secundaria (%)	92.2	24.8	20.2	96.2	156.6
Usuarios de internet (%)	68.6	23.8	6.1	73.7	99.7

La correlacion de Pearson de cada predictor con la variable objetivo es: usuarios de internet $r = 0.83$ (la mas fuerte), matricula secundaria $r = 0.71$, PIB per capita $r = 0.66$, gasto en salud $r = 0.64$ y poblacion urbana $r = 0.61$. Se observa ademas una correlacion muy alta entre PIB per capita y gasto en salud per capita ($r = 0.91$), lo cual anticipa un problema de multicolinealidad que se confirma mas adelante (seccion 3.2).




Figura 1. Matriz de correlacion de Pearson entre la variable objetivo y los predictores.




Figura 2. Dispersión de cada predictor frente a la esperanza de vida. El PIB y el gasto en salud muestran una relación de tipo logarítmico (rendimientos decrecientes); los demás predictores muestran una relación más lineal.

Lectura breve: los países con mayor acceso a internet, mayor matrícula educativa y mayor ingreso tienden a tener mayor esperanza de vida, consistente con la literatura de desarrollo humano. La relación con el ingreso (PIB, gasto en salud) no es estrictamente lineal — se aplanan en niveles altos —, lo cual es una limitación conocida de un modelo puramente lineal (ver sección 5).

3. Modelado

3.1 Configuración

Se dividió el dataset en **80% entrenamiento (104 países)** y **20% prueba (27 países)** usando `train_test_split` de `scikit-learn` con semilla fija `random_state = 42` (definida centralmente en `src/config.py` para garantizar reproducibilidad). Se ajustó una **Regresión Lineal Múltiple** (`sklearn.linear_model.LinearRegression`) sobre los 5 predictores estandarizados en su escala original (sin transformar).

3.2 Coeficientes estimados

Variable	Coeficiente
Intercepto	59.78
PIB per capita (US\$)	5.91e-05
Gasto en salud per capita (US\$)	2.33e-04
Población urbana (%)	0.0203
Matrícula secundaria (%)	0.0238
Usuarios de internet (%)	0.1467

El coeficiente de *usuarios de internet* es el de mayor magnitud estandarizada dado el rango similar de las variables porcentuales: cada punto porcentual adicional de población con acceso a internet se asocia, en promedio y manteniendo lo demás constante, con ~0.15 años más de esperanza de vida.

3.3 Validación de supuestos (sobre el set de entrenamiento)

Supuesto	Prueba	Resultado	Conclusión
Homocedasticidad	Breusch-Pagan	LM = 9.98, p = 0.076	No se rechaza H0: sin evidencia fuerte de heterocedasticidad
Autocorrelación	Durbin-Watson	DW = 2.04	Cercano a 2: sin autocorrelación de primer orden
Normalidad de residuos	Shapiro-Wilk	W = 0.951, p < 0.001	Se rechaza H0: los residuos se desvían de la normalidad
Multicolinealidad	VIF	PIB = 6.26, Salud = 5.29, resto < 4	PIB y gasto en salud requieren atención (colineales entre sí)

(Nota metodológica: dado que `statsmodels` es opcional según los requisitos técnicos del proyecto y no estuvo disponible en el entorno de ejecución, los tests de Breusch-Pagan, Durbin-Watson y VIF se implementaron de forma manual con `scipy` y `scikit-learn` en `src/model.py`, siguiendo sus definiciones estadísticas estándar.)




Figura 3. Residuos vs. valores ajustados (entrenamiento): la dispersion es razonablemente pareja alrededor de cero, sin un patron de embudo marcado.




Figura 4. QQ-plot de residuos: las colas se apartan de la recta teorica, reflejando la falta de normalidad detectada por Shapiro-Wilk.

4. Evaluacion del modelo

Las metricas se calcularon sobre el conjunto de prueba (27 paises, no vistos durante el ajuste) y se comparan con el conjunto de entrenamiento para descartar sobreajuste:

Metrica	Entrenamiento (n=104)	Prueba (n=27)
MAE (anios)	2.49	2.31
MSE	11.65	8.64
RMSE (anios)	3.41	2.94
R ²	0.715	0.817

El desempeno en prueba es igual o mejor que en entrenamiento, lo que descarta sobreajuste (el modelo no "memorizo" el set de entrenamiento); la diferencia es atribuible al tamano pequeno del set de prueba (27 paises). En promedio, el modelo se equivoca por **~2.3 años** al estimar la esperanza de vida de un pais, y explica el **82%** de su variabilidad usando solo 5 indicadores socioeconomicos.




Figura 5. Esperanza de vida real vs. predicha (set de prueba). Los puntos cercanos a la linea $y=x$ indican buenas predicciones.




Figura 6. Residuos vs. predicciones (set de prueba): sin patron sistematico evidente, aunque con un par de valores atipicos (paises con esperanza de vida inusualmente alta o baja para su nivel socioeconomico).

5. Conclusiones, limitaciones y trabajo futuro

5.1 Hallazgos principales

- El acceso a internet, la matricula educativa y el nivel de ingreso de un pais explican en conjunto una parte sustancial ($R^2 = 0.82$) de las diferencias en esperanza de vida al nacer entre paises.
- El predictor individualmente mas asociado con la esperanza de vida es el porcentaje de usuarios de internet ($r = 0.83$), probablemente como proxy de desarrollo institucional y acceso a informacion/servicios, mas que una relacion causal directa.
- PIB per capita y gasto en salud per capita aportan informacion redundante entre si ($r = 0.91$, $VIF > 5$); un modelo mas parsimonioso podria combinarlos o retener solo uno de los dos.

5.2 Sesgos y limitaciones

- **No linealidad no capturada:** la relacion entre ingreso/gasto en salud y esperanza de vida se aplanan en niveles altos (rendimientos decrecientes); una Regresion Lineal simple subestima este efecto en los extremos.
- **Residuos no normales** (Shapiro-Wilk, $p < 0.001$): los intervalos de confianza de los coeficientes deben interpretarse con cautela; no invalida las predicciones puntuales pero si la inferencia estadistica exacta.
- **Multicolinealidad moderada** entre PIB y gasto en salud dificulta aislar el efecto individual de cada uno.
- **Variable de un solo ano (2019) y de nivel-pais:** el modelo no captura dinamicas temporales ni heterogeneidad dentro de cada pais (regiones, grupos socioeconomicos).
- **Variables omitidas:** factores como calidad institucional, desigualdad de ingreso, o acceso efectivo (no solo gasto) a servicios de salud no se incluyeron y podrian confundir las relaciones estimadas.

5.3 Mejoras futuras

- Probar transformaciones no lineales (log del PIB y del gasto en salud) o modelos no lineales (Random Forest, Gradient Boosting) y comparar su desempeno frente a esta linea base.
- Incorporar mas anos (panel de datos) para modelar tendencias y usar validacion cruzada en lugar de un unico split train/test.
- Aplicar regularizacion (Ridge/Lasso) para mitigar la multicolinealidad entre PIB y gasto en salud.
- Incluir variables adicionales de gobernanza, desigualdad (Indice de Gini) y acceso efectivo a servicios de salud.

6. Repositorio GitHub

Enlace del repositorio: <https://github.com/tu-usuario/regresion-lineal-esperanza-vida>

Nota: este es un enlace de referencia (placeholder). El repositorio git local completo, con historial de commits, se entrega junto con este informe; el autor debe crear el repositorio remoto en su cuenta de GitHub y subirlo (git remote add origin <url> && git push -u origin main) para activar el enlace definitivo.

Estructura del proyecto:

```
regresion-lineal-esperanza-vida/
|-- README.md                (instrucciones de instalacion y ejecucion)
|-- requirements.txt          (dependencias con versiones minimas)
|-- Informe_RegresionLineal_PasosPazosJonnathanDavid.pdf (este informe)
|-- src/
|   |-- config.py             (semilla, rutas relativas, indicadores)
|   |-- collect_data.py        (Paso 1: recoleccion via API Banco Mundial)
|   |-- prepare_and_eda.py     (Paso 2: limpieza, diccionario, EDA)
|   |-- model.py               (Paso 3: split, ajuste, supuestos)
|   |-- evaluate.py            (Paso 4: metricas y graficos de evaluacion)
|-- data/
|   |-- raw/                   (JSON crudos + collection_log.csv)
|   |-- processed/             (dataset.csv, train.csv, test.csv, diccionario)
|-- figures/                   (todas las figuras de este informe, en .png)
|-- reports/                   (metricas y estadisticos en .json / .csv)
```

Requisitos tecnicos: Python 3.10+; librerias *pandas*, *numpy*, *scikit-learn*, *matplotlib*, *requests*, *scipy* (version completa en *requirements.txt*); *statsmodels* es opcional. El *README.md* del repositorio detalla los pasos exactos de instalacion y ejecucion de los 4 scripts, en orden, para reproducir integramente este informe a partir de datos crudos.